

# Space Titanic: Análisis de datos

## Presentación de hallazgos y desarrollo

Ramo: Aplicaciones de la matemática en la ingeniería

Universidad Técnica Federico Santa María

Noviembre 2023

## Tabla de Contenidos

- 1 Presentación del problema
- 2 Estadística descriptiva
- 3 Visualización
- 4 Preprocesamiento
- 5 Selección de modelo
- 6 Métricas y análisis de resultados
- 7 Visualizaciones del modelo

# Tabla de Contenidos

- 1 Presentación del problema
- 2 Estadística descriptiva
- 3 Visualización
- 4 Preprocesamiento
- 5 Selección de modelo
- 6 Métricas y análisis de resultados
- 7 Visualizaciones del modelo

## Descripción del problema:

Bienvenido al año 2912, donde se necesitan tus habilidades de ciencia de datos para resolver un misterio cósmico. Hemos recibido una transmisión desde cuatro años luz de distancia y las cosas no pintan bien.

La nave espacial Titanic fue un transatlántico de pasajeros interestelar lanzado hace un mes. Con casi 13.000 pasajeros a bordo, la nave emprendió su viaje inaugural transportando emigrantes de nuestro sistema solar a tres exoplanetas recientemente habitables que orbitan estrellas cercanas.

Mientras rodeaba Alpha Centauri en ruta hacia su primer destino, el tórrido 55 Cancri E, la desprevenida nave espacial Titanic chocó con una anomalía del espacio-tiempo escondida dentro de una nube de polvo.

Lamentablemente, tuvo un destino similar al de su homónimo de 1000 años antes. Aunque la nave permaneció intacta, ¡casi la mitad de los pasajeros fueron transportados a una dimensión alternativa!

# Tabla de Contenidos

- 1 Presentación del problema
- 2 Estadística descriptiva**
- 3 Visualización
- 4 Preprocesamiento
- 5 Selección de modelo
- 6 Métricas y análisis de resultados
- 7 Visualizaciones del modelo



# Estadística descriptiva

```
type: object
```

```
In [9]: train.nunique()
```

```
Out[9]: PassengerId      8693  
HomePlanet              3  
CryoSleep               2  
Cabin                  6560  
Destination             3  
Age                     80  
VIP                     2  
RoomService            1273  
FoodCourt              1507  
ShoppingMall           1115  
Spa                    1327  
VRDeck                 1306  
Name                   8473  
Transported             2  
dtype: int64
```

Figura: train.nunique()

# Estadística descriptiva

	Age	RoomService	FoodCourt	ShoppingMall	Spa	VRDeck
count	8514.000000	8512.000000	8510.000000	8485.000000	8510.000000	8505.000000
mean	28.827930	224.687617	458.077203	173.729169	311.138778	304.854791
std	14.489021	666.717663	1611.489240	604.696458	1136.705535	1145.717189
min	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000
25%	19.000000	0.000000	0.000000	0.000000	0.000000	0.000000
50%	27.000000	0.000000	0.000000	0.000000	0.000000	0.000000
75%	38.000000	47.000000	76.000000	27.000000	59.000000	46.000000
max	79.000000	14327.000000	29813.000000	23492.000000	22408.000000	24133.000000

Figura: train.describe()



# Tabla de Contenidos

- 1 Presentación del problema
- 2 Estadística descriptiva
- 3 Visualización**
- 4 Preprocesamiento
- 5 Selección de modelo
- 6 Métricas y análisis de resultados
- 7 Visualizaciones del modelo

## Variables cuantitativas




Figura: Distribución de edades




Figura: Gasto en servicio a la habitación

## Variables cuantitativas




Figura: Gasto en patio de comidas




Figura: Gasto en centro comercial

## Variables cualitativas

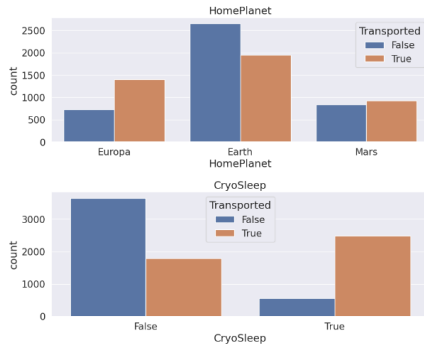


Figura: Visualización de las columnas HomePlanet y CryoSleep

## Variables cualitativas




Figura: Visualización de las columnas Destination y Vip

# Tabla de Contenidos

- 1 Presentación del problema
- 2 Estadística descriptiva
- 3 Visualización
- 4 Preprocesamiento**
- 5 Selección de modelo
- 6 Métricas y análisis de resultados
- 7 Visualizaciones del modelo

# Transformación de los datos de entrenamiento

	PassengerId	CryoSleep	Age	VIP	RoomService	FoodCourt	ShoppingMall	Spa	VRDeck	Transported	...
0	0001_01	0	39.0	0	0.0	0.0	0.0	0.0	0.0	0	...
1	0002_01	0	24.0	0	109.0	9.0	25.0	549.0	44.0	1	...
2	0003_01	0	58.0	1	43.0	3576.0	0.0	6715.0	49.0	0	...
3	0003_02	0	33.0	0	0.0	1283.0	371.0	3329.0	193.0	0	...
4	0004_01	0	16.0	0	303.0	70.0	151.0	565.0	2.0	1	...
...	...	...	...	...	...	...	...	...	...	...	...
8688	9278_01	0	41.0	1	0.0	6819.0	0.0	1643.0	74.0	0	...
8689	9278_01	1	15.0	0	0.0	0.0	0.0	0.0	0.0	0	...
8690	9279_01	0	26.0	0	0.0	0.0	1872.0	1.0	0.0	1	...
8691	9280_01	0	32.0	0	0.0	1049.0	0.0	353.0	3235.0	0	...
8692	9280_02	0	44.0	0	126.0	4680.0	0.0	0.0	12.0	1	...

8493 rows • 27 columns

Total_spending	HomePlanet_Earth	HomePlanet_Europa	HomePlanet_Mars	Destination_55 Cancri	Destination_PSO J1118-02	Destination_TRAPPIST-1e	Cabin_Deck_A	Cabin_Deck_B	Cabin_Deck_C
0.0	0	1	0	0	0	0	1	0	1
756.0	1	0	0	0	0	0	1	0	0
10380.0	0	1	0	0	0	0	1	1	0
8176.0	0	1	0	0	0	0	1	1	0
1091.0	1	0	0	0	0	0	1	0	0
774.0	1	0	0	0	0	1	0	0	0
1084.0	1	0	0	0	0	0	1	0	0
0.0	1	0	0	0	0	0	1	0	0
1016.0	1	0	0	0	0	0	1	0	0
0.0	0	1	0	1	0	0	0	0	1
0.0	0	1	0	0	0	0	1	0	1
8187.0	0	1	0	1	0	0	0	0	1
1206.0	0	0	1	0	0	0	1	0	0
606.0	1	0	0	0	0	0	1	0	0
1003.0	1	0	0	0	0	0	1	0	0

Figura: Data modificada

Figura: Data modificada

# Transformación de los datos de prueba

index	PassengerId	CryoSleep	Age	VIP	RoomService	FoodCourt	ShoppingMall	Spa	VRDeck	Total_spending
0	0013_01	1	27.0	0	0.0	0.0	0.0	0.0	0.0	0.0
1	0018_01	0	19.0	0	0.0	9.0	0.0	2823.0	0.0	2832.0
2	0019_01	1	31.0	0	0.0	0.0	0.0	0.0	0.0	0.0
3	0021_01	0	38.0	0	0.0	9552.0	0.0	181.0	585.0	7418.0
4	0023_01	0	20.0	0	10.0	0.0	635.0	0.0	0.0	645.0
5	0027_01	0	31.0	0	0.0	1815.0	283.0	113.0	80.0	2051.0
6	0029_01	1	21.0	0	0.0	0.0	0.0	0.0	0.0	0.0
7	0032_01	1	20.0	0	0.0	0.0	0.0	0.0	0.0	0.0
8	0032_02	1	23.0	0	0.0	0.0	0.0	0.0	0.0	0.0
9	0033_01	0	24.0	0	0.0	839.0	0.0	0.0	0.0	839.0
10	0037_01	0	19.0	0	338.0	3.0	136.0	237.0	0.0	715.0

Figura: Data modificada

Total_spending	RoomPlanet_South	RoomPlanet_Europe	RoomPlanet_West	Destination_30_Consults	Destination_F150_210_0_10	Destination_16000011to	Cabin_Deck_A	Cabin_Deck_B	Cabin_Deck_C
0.0	0	1	0	0	0	1	0	0	0
186.0	1	0	0	0	0	1	0	0	0
10388.0	0	1	0	0	0	1	1	0	0
81782.0	0	1	0	0	0	0	1	0	0
1981.0	1	0	0	0	0	1	0	0	0
1740.0	1	0	0	0	0	1	0	0	0
9884.0	1	0	0	0	0	0	1	0	0
6.0	1	0	0	0	0	1	0	0	0
1218.0	1	0	0	0	0	1	0	0	0
0.0	0	1	0	1	0	0	0	0	1
0.0	0	1	0	0	0	1	0	0	1
84816.0	0	1	0	0	0	0	0	0	1
1088.0	0	0	1	0	0	1	0	0	0
8888.0	1	0	0	0	0	1	0	0	0
10010.0	1	0	0	0	0	1	0	0	0

Figura: Data modificada



# Tabla de Contenidos

- 1 Presentación del problema
- 2 Estadística descriptiva
- 3 Visualización
- 4 Preprocesamiento
- 5 Selección de modelo**
- 6 Métricas y análisis de resultados
- 7 Visualizaciones del modelo

# Métricas

```
Random forest accuracy: 0.804552590266876
```

```
Adaboost accuracy: 0.793171114599686
```

```
Gaussian NB accuracy: 0.6620879120879121
```

```
Multinomial NB accuracy: 0.6840659340659341
```

**Figura:** Accuracy score de 4 modelos

# Tabla de Contenidos

- 1 Presentación del problema
- 2 Estadística descriptiva
- 3 Visualización
- 4 Preprocesamiento
- 5 Selección de modelo
- 6 Métricas y análisis de resultados**
- 7 Visualizaciones del modelo

## Accuracy score y matriz de confusión

```
[155] accuracy = accuracy_score(y_true['Transported'], y_pred)
      print (accuracy)

0.5288878762618566
```

Figura: Accuracy score




Figura: Matriz de confusión

# Tabla de Contenidos

- 1 Presentación del problema
- 2 Estadística descriptiva
- 3 Visualización
- 4 Preprocesamiento
- 5 Selección de modelo
- 6 Métricas y análisis de resultados
- 7 Visualizaciones del modelo

# Visualizaciones




Figura: Visualizacion

## Conclusiones

Verdaderos Positivos (VP): 2219

Falsos Positivos (FP): 1964

Verdaderos Negativos (VN): 0

Falsos Negativos (FN): 0

Esta matriz de confusión sugiere que nuestro modelo hizo predicciones positivas correctas (2219) pero realizó un gran número de predicciones falsas positivas (1964). El modelo no hizo ninguna predicción negativa correcta, y no hubo instancias en las que predijo correctamente la clase negativa.

# Muchas Gracias